

Jędrzej Wydra



Prawo sztucznej inteligencji

Techniczne podstawy AI

warsztaty

Uniwersytet im. Adama Mickiewicza w Poznaniu
Wydział Prawa i Administracji

Prawo

Spis treści

ROZDZIAŁ 1. SYSTEM A MODEL SZTUCZNEJ INTELIGENCJI	6
PODROZDZIAŁ 1.1. ZASADY UCZESTNICTWA I ZALICZENIA ZAJĘĆ.....	6
<i>Obecność na zajęciach</i>	<i>6</i>
<i>Zaliczenie zajęć.....</i>	<i>6</i>
PODROZDZIAŁ 1.2. TREŚĆ ZAJĘĆ.....	7
PODROZDZIAŁ 1.3. ZAGADNIENIA WSTĘPNE	8
PODROZDZIAŁ 1.4. PODSTAWOWE POJĘCIA	8
ROZDZIAŁ 2. W JAKI SPOSÓB AI SIĘ UCZY?	10
PODROZDZIAŁ 2.1. DANE TRENINGOWE, DANE WALIDACYJNE, DANE TESTOWE	10
PODROZDZIAŁ 2.2. ALGORYTMY UCZENIA	11
PODROZDZIAŁ 2.3. TYPY UCZENIA W ZALEŻNOŚCI OD ZADANIA	13
PODROZDZIAŁ 2.4. TYPY UCZENIA W ZALEŻNOŚCI OD SPOSOBU DOSTARCZANIA DANYCH	15
ROZDZIAŁ 3. MODELE JĘZYKOWE JAKO PRZYKŁAD MODELI AI OGÓLNEGO PRZEZNACZENIA	16
PODROZDZIAŁ 3.1. WIELKIE MODELE JĘZYKOWE I ICH (NIE)WIELKIE MOŻLIWOŚCI	16
PODROZDZIAŁ 3.2. DYSKUSJE	18
PYTANIA NA ZALICZENIE	20

Niniejszy skrypt został przygotowany dla studentów prawa w celu ułatwienia uczestnictwa w warsztatach z prawa sztucznej inteligencji. Skrypt stanowi kompletne materiały niezbędne i wystarczające do zaliczenia części przedmiotu dotyczącej technicznych podstaw AI.

Materiały te zostały pomyślane jako notatki, więc studenci mogą swoją pełną uwagę nakierować na aktywne uczestnictwo w zajęciach z ewentualnym dopisywaniem własnych wyjaśnień lub intuicji na marginesach.

Celem opracowania nie jest nauczanie studentów programowania czy matematyki, lecz umożliwienie świadomego rozumienia podstawowych pojęć technicznych, które coraz częściej pojawiają się w dyskursie prawnym. Wszystkie przykłady i definicje zostały przygotowane, aby budować intuicję wśród studentów prawa, dla których głębokie szczegóły techniczne nie są niezbędne. Stąd w tekście znajduje się dużo uproszczeń.

Definicje przedstawione w niniejszym skrypcie zostały opracowane w sposób dostosowany do potrzeb studentów prawa, z naciskiem na intuicję i praktyczne rozumienie. Odwołania do literatury należy traktować raczej jako punkt wyjścia do dalszych, samodzielnych studiów dla osób zainteresowanych pogłębieniem tematu.

W tekście pojawiają się również liczne odesłania do programów napisanych w języku Python w IDE¹ Google Colab. To środowisko umożliwia uruchamianie tychże programów bez potrzeby instalacji dodatkowego oprogramowania na własnym urządzeniu i mogą być otwierane za pośrednictwem komputera, tabletu lub smartfona. Niemniej jednak analiza tych programów i ich kodu źródłowego jest zadaniem wyłącznie dla osób zaciekawionych, bowiem w żadnym przypadku nie jest konieczna do zaliczenia przedmiotu.

Podstawową i uzupełniającą literaturą pozostaje wykaz zamieszczony w sylabusie, tzn:

Obowiązkowa:

1. Fischer B., Pązik A., Świerczyński M., *Prawo sztucznej inteligencji i nowych technologii*, Warszawa 2024;
2. Lai L., Świerczyński M. (red.), *Prawo sztucznej inteligencji*, Warszawa 2020;
3. Jędrzejczak M., Szoszkiewicz Ł., Wydra J. (red.), *AI Act. Akt w sprawie sztucznej inteligencji. Komentarz*, Warszawa 2025 (w druku).

Uzupełniająca:

1. Russel S., Norvig P., *Artificial Intelligence: A Modern Approach*, wydanie 4, Pearson 2020 (wydanie polskie: Russel S., Norvig P., *Sztuczna inteligencja. Nowe spojrzenie*, wydanie 4, Wydawnictwo Helion 2023);
2. James G., Witten D., Hastie T., Tibshirani R., *An introduction to statistical learning with applications in Python*, Springer 2013.

Niemniej jednak literaturę wartą przejrzania stanowi poniższa lista, do pozycji której znajdują się przypisy w tekście skryptu w kolejności zgodnej z poniższą:

1. Kaplan, A., & Haenlein, M. (2019). *Siri, Siri, in my hand: Who's the fairest in the land? On the interpretations, illustrations, and implications of artificial intelligence*. *Business horizons*, 62(1), 15-25;
2. A. Jung, *Machine Learning: The Basics*, Springer, Singapore, 2022;
3. Commission Guidelines on the definition of an artificial intelligence system established by Regulation (EU) 2024/1689 (AI Act), C(2025) 924, 6.02.2025 r.

¹ Integrated Development Environment

4. Wydra, J., Smaga, Ł., & Matuszewski, S. (2025). *Interval Estimation of Thermal Summation Parameters in Forensically Important Insects*, ResearchSquare.
5. Awad, M., Khanna, R. *Machine Learning*. w: *Efficient Learning Machines*. Apress, Berkeley, CA 2015
6. Wydra, J., Smaga, Ł., & Matuszewski, S. (2025). *Forensically useful mid-term and short-term temperature reconstruction for quasi-indoor death scenes*. *Science & Justice*, 65(1), 43-51.
7. Bishop, Christopher M. *Pattern Recognition and Machine Learning*. New York: Springer 2006
8. K.P. Murphy, *Machine learning: a probabilistic perspective*, London 2012
9. <https://platform.openai.com/docs/guides/text>
10. A. Plucińska, E. Pluciński, *Probabilistyka*, Wydawnictwo WNT, Warszawa 2017
11. Sun, Y., Sheng, D., Zhou, Z., & Wu, Y. (2024). *AI hallucination: towards a comprehensive classification of distorted information in artificial intelligence-generated content*. *Humanities and Social Sciences Communications*, 11(1), 1-14.

Z perspektywy studentów prawa oczywiście najważniejszym źródłem pozostaje Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2024/1689 z 13 czerwca 2024 r. w sprawie ustanowienia zharmonizowanych przepisów dotyczących sztucznej inteligencji (tzw. akt o sztucznej inteligencji), czyli popularny AI Act.

Niniejszy skrypt jest dostępny on-line [tutaj](#).

Życzę owocnej pracy z materiałami i satysfakcji z odkrywania podstaw AI.

Jędrzej Wydra

Rozdział 1. System a model sztucznej inteligencji

Podrozdział 1.1. Zasady uczestnictwa i zaliczenia zajęć

Warsztaty z prawa sztucznej inteligencji obejmują dwie części: (1) techniczne podstawy AI, prowadzone przez mgr. Jędrzeja Wydrę oraz (2) prawne aspekty AI, prowadzone przez dr Marię Jędrzejczak. Każda część obejmuje cztery spotkania po 80–90 minut na studiach stacjonarnych lub dwa i pół spotkania po 150 minut na studiach niestacjonarnych. W przypadku zajęć niestacjonarnych przewidziana jest 15-minutowa przerwa.

Zaliczenie przedmiotu będzie miało formę kolokwium ustnego obejmującego dwie części. Każda z nich zostanie oceniona oddzielnie, a ocena końcowa będzie stanowiła średnią z obu wyników.

Szczegółowe zasady uczestnictwa i zaliczenia części dotyczącej prawnych aspektów AI zostaną przedstawione przez dr Marię Jędrzejczak. Szczegółowe zasady części dotyczącego technicznych aspektów AI znajdują się poniżej.

Obecność na zajęciach

1. Obecność na zajęciach z technicznych podstaw AI nie jest obowiązkowa, ale jest zalecana.
2. Sprawdzanie obecności odbywa się jedynie w celach statystycznych.
3. Każda aktywność studenta podczas zajęć jest nagradzana plusami, które wpływają na ocenę końcową.
4. Poprzez aktywność należy rozumieć: zadawanie pytań, udział w dyskusji, formułowanie odpowiedzi na pojawiające się w trakcie zajęć pytania oraz formułowanie komentarzy do bieżących zagadnień.
5. Student otrzymuje plusy, o których mowa w punkcie 3 niezależnie od tego czy odpowiedzi i komentarze, o których mowa w punkcie 4 są poprawne czy nie.
6. Student może stawiać dowolne pytania wynikające z zainteresowania tematem przedmiotu niezależnie od swojej oceny ich trafności. Pytania stanowią aktywność, o której mowa w punkcie 4 niezależnie od ich obiektywnej trafności.
7. Pytania o których mowa w punkcie 4 mogą być zadawane w dowolnym czasie, w szczególności na zajęciach lub poza nimi (osobiście lub e-mailowo). Pytania nie muszą być związane z aktualnie omawianym zagadnieniem, mogą dotyczyć treści przeszłych, przyszłych, jak również mogą stanowić dygresję, jeśli tylko zaspokajają potrzebę dążenia do wiedzy.
8. Student samodzielnie ocenia swoją aktywność na zajęciach i na koniec każdego spotkania informuje prowadzącego o swojej ocenie. Ocena ma formę liczby plusów.

Zaliczenie zajęć

1. Zaliczenie całości przedmiotu odbywa się na podstawie średniej ocen z poszczególnych części.
2. Zaliczenie części dotyczącej technicznych podstaw AI odbywa się na podstawie kolokwium ustnego, podczas którego student otrzymuje jedno pytanie spośród tych dostępnych na końcu niniejszego skryptu lub pytanie podobne.
3. Pytanie, o którym mowa w punkcie 2 jest wybierane poprzez losowanie bez zwracania.
4. Po wylosowaniu pytania, student otrzymuje czas na przygotowanie się do odpowiedzi.
5. Podczas odpowiedzi na pytanie, o którym mowa w punkcie 2 student może otrzymywać dodatkowe pytania mające charakter doprecyzowujący lub naprowadzający.
6. Podczas przygotowywania się do odpowiedzi, jak również podczas samej odpowiedzi, student może korzystać z niniejszych materiałów.
7. Ocena odpowiedzi studenta ma charakter jakościowy.
8. Student, który wykazywał się małą aktywnością w trakcie zajęć może wylosować dwa pytania i wybrać na które chce odpowiadać. Uprawnienie można wykorzystać tylko raz.

9. Student, który wykazywał się dużą aktywnością w trakcie zajęć korzysta z uprawnienia, o którym mowa w punkcie 9 oraz otrzymuje ocenę podwyższoną o jeden.
10. Uprawnienia, o których mowa w punkcie 8 i 9 dotyczą tylko zaliczenia części dotyczącej technicznych podstaw AI.
11. Uprawnienia, o których mowa w punktach 8 i 9 nie przysługują w terminie poprawkowym.
12. Po odbyciu wszystkich przewidzianych spotkań, prowadzący oceni aktywność każdego studenta jako „małą”, „dużą” lub niekwalifikującą się do przyznania uprawnień, o których mowa w punktach 8 i 9. Ocena odbędzie się na podstawie plusów zbieranych przez wszystkich studentów.
13. Student, którego aktywność została oceniona jako mała lub duża zostanie o tym poinformowany przed wylosowaniem pytania podczas kolokwium ustnego.

Podrozdział 1.2. Treść zajęć

Sylabus przedmiotu Prawo sztucznej inteligencji przewiduje sześć treści programowych:

1. pojęcie i rodzaje systemów sztucznej inteligencji;
2. kategorie ryzyka zastosowania sztucznej inteligencji;
3. zakazane praktyki w zakresie sztucznej inteligencji;
4. środki ochrony prawnej przewidziane w AI Act;
5. odpowiedzialność za szkody wyrządzone przez systemy sztucznej inteligencji;
6. wprowadzenie do informatycznych podstaw sztucznej inteligencji.

Zagadnienia z punktów 1 i 6 będą realizowane w ramach części poświęconej technicznym podstawom AI.

W ramach punktu „pojęcie i rodzaje sztucznej inteligencji” zostanie wyjaśnione czym w ogóle jest sztuczna inteligencja i jaką rolę w jej konstrukcji odgrywają modele matematyczne, w tym modele uczenia maszynowego. Aby wyrobić w studentach intuicję co jest przedmiotem regulacji AI Act zostanie przeanalizowana definicja systemu AI, zarówno w jej wymiarze technicznym, jak i w kontekście konsekwencji społecznych.

Sztuczna inteligencja jako dziedzina informatyki dzieli się zasadniczo na dwa nurty: klasyczną sztuczną inteligencję oraz uczenie maszynowe. W ramach kursu przedstawione zostaną przykłady zastosowań podejścia klasycznego, jednak główny nacisk zostanie położony na uczenie maszynowe. To właśnie ono, dzięki możliwości uczenia systemu komputerowego na podstawie przykładów, umożliwiło budowę zaawansowanych systemów inteligentnych bez konieczności szczegółowej znajomości każdej dziedziny, w której system ma działać. W przypadku klasycznej sztucznej inteligencji taka wiedza była niezbędna.

Oprócz podziału na klasyczną sztuczną inteligencję i uczenie maszynowe omówione zostaną także podstawowe typy systemów opartych na uczeniu maszynowym. Z jednej perspektywy wyróżnia się tu modele tworzone z wykorzystaniem technik takich jak uczenie nadzorowane i nienadzorowane. Z innej, można je klasyfikować według sposobu w jakim dostarczane są dane treningowe, tj. na systemy uczące się offline oraz uczące się online.

Szczególna uwaga zostanie poświęcona generatywnej sztucznej inteligencji oraz modelom AI ogólnego przeznaczenia w rozumieniu AI Act. Studenci poznają mechanizmy działania takich systemów i rozumieją, w jaki sposób programy, takie jak ChatGPT, przetwarzają oraz generują tekst.

W ramach punktu „wprowadzenie do informatycznych podstaw sztucznej inteligencji” studenci zapoznają się z procesem tworzenia modelu AI. Szczegółowo omówione zostaną funkcje danych treningowych, walidacyjnych i testowych, a także różnice między nimi.

Przedstawione zostaną podstawowe problemy modeli sztucznej inteligencji, takie jak przetrenowanie, niewystarczające wytrenowanie czy zagrożenia wynikające z niezrównoważenia danych. Dzięki temu studenci wykształcą intuicję potrzebną do oceny ograniczeń systemów AI.

W ramach kursu przewidziane są także dyskusje na temat odpowiedzialnego wykorzystania i regulowania systemów sztucznej inteligencji. Szczególny nacisk zostanie położony na to, jak robić to w sposób bezpieczny, etyczny i zrównoważony.

Podrozdział 1.3. Zagadnienia wstępne

Podczas zajęć pojęcia „sztuczna inteligencja” i „AI” będą stosowane zamiennie. Termin „sztuczna inteligencja” jest polskim określeniem technologii omawianych w ramach kursu, natomiast skrót „AI” (od angielskiego „Artificial Intelligence”) powszechnie funkcjonuje także w języku polskim i w odróżnieniu od rodzimego skrótu SI, nie stwarza ryzyka pomyłki z międzynarodowym systemem jednostek (system SI). Ponadto, skrót AI utrwalił się w wyrażeniu AI Act, używanym jako określenie Rozporządzenia Parlamentu Europejskiego i Rady (UE) 2024/1689 z 13 czerwca 2024 r. w sprawie ustanowienia zharmonizowanych przepisów dotyczących sztucznej inteligencji (tzw. aktu o sztucznej inteligencji). W dalszej części zajęć rozporządzenie to będziemy nazywać właśnie AI Act.

Pytania:

1. Jakie jest Pani/Pana zdanie o AI? Czy odczuwa Pani/Pan jakiś strach w związku z rozwojem AI?
2. Gdzie – Pani/Pana zdaniem – wykorzystuje się AI?
3. Jakie są Pani/Pana oczekiwania względem zajęć?

Podrozdział 1.4. Podstawowe pojęcia

Definicja 1. (sztuczna inteligencja/AI)

Sztuczna inteligencja (AI) jest zdolnością systemu do prawidłowego interpretowania danych pochodzących z zewnętrznych źródeł, nauki na ich podstawie oraz wykorzystywania tej wiedzy, aby wykonywać określone zadania i osiągać cele poprzez elastyczne dostosowanie².

Przykład 1.

Wyszukiwarka Google wykorzystuje sztuczną inteligencję od początku swojego istnienia. Zwraca użytkownikowi wyniki zapytań na podstawie treści zapytania, lokalizacji, ruchu w sieci Internet i innych czynników. W efekcie to samo zapytanie będzie skutkowało innymi wynikami w zależności od choćby miejsca z jakiego użytkownik łączy się z Internetem oraz czasu w jakim to robi.

Definicja 2. (model sztucznej inteligencji/model AI)

Modelem sztucznej inteligencji jest algorytm lub ich układ nadający systemowi zdolność sztucznej inteligencji, o której mowa w definicji 1.

Przykład 2.

Pierwotnie wyszukiwarka Google wykorzystywała tzw. łańcuchy Markova do indeksowania stron internetowych i na ich podstawie nadawała im priorytet w wynikach wyszukiwania. Wówczas łańcuch Markova był modelem sztucznej inteligencji (więcej o łańcuchach Markova w rozdziale 3). Współcześnie wyszukiwarka Google wykorzystuje modele będące udoskonaleniem łańcuchów Markova.

² Kaplan, A., & Haenlein, M. (2019). *Siri, Siri, in my hand: Who's the fairest in the land? On the interpretations, illustrations, and implications of artificial intelligence*. Business horizons, 62(1), 15-25.

Definicja 3. (model uczenia maszynowego)

Model uczenia maszynowego jest funkcją (w sensie logiki formalnej), której dziedziną jest rodzina zbiorów danych wejściowych, a przeciwdziedziną jest rodzina zbiorów danych wyjściowych. Parametry tej funkcji są wyznaczone na podstawie danych treningowych (więcej o danych treningowych w rozdziale 2)³.

Przykład 3.

Model filtru antyspamowego przyjmuje jako dane wejściowe treść e-maila i na tej podstawie generuje etykietę „spam” lub „nie-spam”. Wcześniej, na podstawie dużej bazy danych zawierającej wiadomości e-mailowe, gdzie każda wiadomość posiadała etykietę „spam” lub „nie-spam” model odnalazł zależność treści e-maila od etykiety. Zależność została zakodowana w parametrach modelu.

Konwencja 1.

Zgodnie z wytycznymi Komisji Europejskiej⁴ nie wszystkie systemy wykorzystujące metody uczenia maszynowego będą systemami AI w rozumieniu AI Act. Z matematycznego punktu widzenia jest to osobiwe. Należy jednak zwrócić uwagę, że z perspektywy społecznej ma to głęboki sens, bowiem samo zastosowanie algorytmu uczącego nie predestynuje do miana sztucznej inteligencji. Tak np. wiele programów do obliczeń (np. MS Excel) może wykorzystywać algorytmy uczenia maszynowego do choćby wykrywania trendu w danych. Nie będzie to jednak sztuczna inteligencja, bo w tym przypadku algorytm nie podejmuje żadnych decyzji, tylko zwraca pewne wartości liczbowe podlegające późniejszej interpretacji. Cel wykorzystania algorytmu jest inny, chociaż formalnie działa w ten sam sposób.

Definicja 4. (system sztucznej inteligencji/system AI)

W rozumieniu AI Act, systemem AI jest system maszynowy, który został zaprojektowany do działania z różnym poziomem autonomii po jego wdrożeniu oraz który może wykazywać zdolność adaptacji po jego wdrożeniu, a także który – na potrzeby wyraźnych lub dorozumianych celów – wnioskuje, jak generować na podstawie otrzymanych danych wejściowych wyniki, takie jak predykcje, treści, zalecenia lub decyzje, które mogą wpływać na środowisko fizyczne lub wirtualne⁵.

³ A. Jung, *Machine Learning: The Basics*, Springer, Singapore, 2022

⁴ Commission Guidelines on the definition of an artificial intelligence system established by Regulation (EU) 2024/1689 (AI Act), C(2025) 924, 6.02.2025 r.

⁵ Art. 3 pkt 1 AI Act

Rozdział 2. W jaki sposób AI się uczy?

Podrozdział 2.1. Dane treningowe, dane walidacyjne, dane testowe

Kazus 1. (Czy AI może przewidzieć wyrok sądu?)

Zbiór danych zawierający 11 478 spraw rozstrzygniętych przez Europejski Trybunał Praw Człowieka jest publicznie dostępny [tutaj](#). Korzystając z nich można wytrenować model AI, aby przewidywać czy w konkretnej sprawie Trybunał orzeknie o naruszeniu praw człowieka. Na podstawie informacji takich jak fakty wzięte w sprawie pod uwagę, data, ważność sprawy, nazwiska sędziów i nazwa pozwanego państwa można poprawnie przewidywać wyrok Trybunału z dokładnością rzędu 87%. (Szczegółowy opis zmiennych jest dostępny w dokumentacji danych [tutaj](#)). Ten optymistyczny wynik przede wszystkim oznacza, że Trybunał orzeka według pewnego wzorca, czyli wyroki nie są przypadkowe lub nieprzewidywalne. Niemniej jednak, to czy taki model byłby użyteczny w praktyce zależy od jakości danych wykorzystanych do jego trenowania. A ustalenie tego wymaga dalszych i szczegółowych badań.

Dla zainteresowanych kod Pythona wspomnianego modelu dostępny jest w [notatniku Colab](#).

Definicja 4. (dane treningowe)

W rozumieniu AI Act, danymi treningowymi są dane wykorzystywane do trenowania systemu AI poprzez dopasowanie jego parametrów podlegających uczeniu⁶.

Doprecyzowanie 1.

Szczególnie w starszych opracowaniach można znaleźć pojęcie „dane uczące”. Pierwotnie „training data” było tłumaczone właśnie jako „dane uczące”. Jednak wpływ języka korporacyjnego i postępująca anglicyzacja języka polskiego wyparła formę „dane uczące” na rzecz „danych treningowych”. Polska wersja AI Act przyjęła tę drugą, popularniejszą formę. W efekcie, w kontekście prawnym należy posługiwać się pojęciem „danych treningowych”. W szerszym kontekście, pojęcia można traktować jako synonimy.

Definicja 5. (dane walidacyjne)

W rozumieniu AI Act, danymi walidacyjnymi są dane wykorzystywane do oceny trenowanego systemu AI oraz do dostrajania jego parametrów niepodlegających uczeniu oraz procesu uczenia, między innymi w celu zapobiegania niedostatecznemu wytrenowaniu lub przetrenowaniu⁷.

Definicja 6. (dane testowe)

W rozumieniu AI Act, danymi testowymi są dane wykorzystywane do przeprowadzenia niezależnej oceny systemu AI w celu potwierdzenia oczekiwanej skuteczności działania tego systemu przed wprowadzeniem go do obrotu lub oddaniem go do użytku⁸.

Definicja 7. (zrównoważony zbiór danych)

Zbiór danych jest zrównoważony, gdy wszystkie wartości zmiennej przewidywanej (zmiennej y) pojawiają się ze zbliżoną częstością.⁹ W przeciwnym przypadku mówimy o danych niezrównoważonych.

⁶ Art. 3 pkt 29 AI Act

⁷ Art. 3 pkt 30 AI Act

⁸ Art. 3 pkt 32 AI Act

⁹ S. Russell, P. Norvig, *Artificial Intelligence: A Modern Approach*, Harlow 2021

Podrozdział 2.2. Algorytmy uczenia

Co do zasady celem modelu uczenia maszynowego jest poprawne odnalezienie wzorca występującego w danych treningowych. W efekcie model będzie błędnie przewidywał większość sytuacji rzeczywistych, ale z zastrzeżeniem, że przeciętny błąd modelu jest odpowiednio niski. Pożądany poziom błędu zależy od konkretnego zastosowania systemu AI.



Rycina 1. Czerwona linia jest modelem poprawnie dopasowanym do danych reprezentowanych przez niebieskie punkty.

Animacja wizualizująca proces uczenia dostępna jest w [notatniku Colab](#).

Definicja 8. (funkcja straty)

Funkcja straty $L(\hat{\mathbf{y}}, \mathbf{y})$ jest miarą błędu pomiędzy wartościami przewidywanymi $\hat{\mathbf{y}}$, a faktycznymi \mathbf{y} ¹⁰. Wektory $\hat{\mathbf{y}} = (\hat{y}_1, \hat{y}_2, \dots, \hat{y}_n)$, $\mathbf{y} = (y_1, y_2, \dots, y_n)$ są odpowiednio wektorami faktycznych danych wyjściowych i idealnych wartości danych wyjściowych.

Przykład 4.

Jedną z najczęściej wykorzystywanych funkcji straty (w tzw. modelach regresji) jest błąd średniokwadratowy:

$$L(\hat{\mathbf{y}}, \mathbf{y}) = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Definicja 9. (przetrenowanie modelu)

Model jest przetrenowany (przeuczony), gdy zbyt dokładnie odtwarza dane treningowe¹¹.


Przykład 5.

Rozważmy proste dwuwymiarowe dane jak na rycinie 2. Niebieski model jest przetrenowany, ponieważ nauczył się danych treningowych na pamięć i nie potrafi poprawnie operować poza nimi. Jego przeciętny błąd na danych treningowych wynosi 0, ale na danych testowych wynosi 30.01. Dla porównania, czerwony model nie nauczył się danych na pamięć, ale poprawnie

¹⁰ S. Russell, P. Norvig, *Artificial Intelligence: A Modern Approach*, Harlow 2021

¹¹ S. Russell, P. Norvig, *Artificial Intelligence: A Modern Approach*, Harlow 2021

wykrył wzorec, w efekcie jego błąd na danych treningowych to 8.82, ale na danych testowych to już tylko 9.24.



Rycina 2. Porównanie modelu przetrenowanego i odpowiednio wytrenowanego. Niebieski model jest przetrenowany. Czerwony model jest odpowiednio wytrenowany. Niebieskie punkty to dane treningowe obu modeli, czerwone punkty to dane testowe obu modeli.

Dla zainteresowanych kod Pythona dostępny jest w [notatniku Colab](#).


Definicja 10. (niedostateczne wytrenowanie modelu)

Model jest niedostatecznie wytrenowany (niedouczone), gdy niepoprawnie odtwarza zależności z danych treningowych¹².

Przykład 6.

Rozważmy proste dwuwymiarowe dane jak na rycinie 3. Niebieski model jest niedostatecznie wytrenowany, ponieważ nie odtwarza poprawnie wzorca z danych. W efekcie jego przeciętny błąd na danych treningowych wynosi 10.61, a na danych testowych wynosi 11.69. Dla porównania, czerwony model jest odpowiednio wytrenowany i poprawnie wykrył wzorec. Jego przeciętny błąd na danych treningowych to 8.82, a na danych testowych to 9.24.

¹² S. Russell, P. Norvig, *Artificial Intelligence: A Modern Approach*, Harlow 2021



Rycina 3. Porównanie modelu niedostatecznie wytrenowanego i odpowiednio wytrenowanego. Niebieski model jest niedostatecznie wytrenowany. Czerwony model jest odpowiednio wytrenowany. Niebieskie punkty to dane treningowe obu modeli, czerwone punkty to dane testowe obu modeli.

Dla zainteresowanych kod Pythona dostępny jest w [notatniku Colab](#).


Podrozdział 2.3. Typy uczenia w zależności od zadania

Typ modelu uczenia maszynowego jest wyznaczony przez wykorzystany typ uczenia. Do najpopularniejszych należą: uczenie nienadzorowane, uczenie nadzorowane, uczenie wzmacniane i uczenie z nadzorem własnym. Najbardziej podstawowymi są uczenie nienadzorowane i nadzorowane. Pozostałe są bardziej zaawansowane i do pewnego stopnia stanowią rozwinięcie tych podstawowych, stąd dla wyrobienia niezbędnych intuicji wystarczy omówienie uczenia nienadzorowanego i nadzorowanego.

Kazus 2. (uczenie nienadzorowane w szacowaniu czasu śmierci¹³)

Gdy zostanie znalezione ciało denata, który zmarł w niewyjaśnionych okolicznościach, jedną z podstawowych informacji do ustalenia w toku śledztwa jest prawdopodobny czas śmierci. W sytuacji, gdy zwłoki zostały odnalezione w stosunkowo krótkim okresie pośmiertnym, zwykle wystarczające są metody zwykłej medycyny sądowej. Gdy jednak ciało leżało odpowiednio długo, to proces rozkładu może uniemożliwić pracę medykom sądowym. Wówczas użyteczne może okazać się badanie śladów entomologicznych, tzn. owadów, które żyją na zwłokach. Owady mają przewidywalny czas rozwoju, więc określając wiek owada można oszacować czas śmierci. Ostatnio jednak okazało się, że wewnątrz jednej populacji owadów mogą istnieć grupy o innej dynamice rozwoju, a czynnik odpowiedzialny za te różnice nie do końca był znany. Korzystając modelu bazującego na uczeniu nienadzorowanym udało się rozdzielić populację owadów i podzielić osobniki według szybkości ich rozwoju. Umożliwiło to dalsze analizy i powiązanie czasu rozwoju owada z jego wielkością.

¹³ Wydra, J., Smaga, Ł., & Matuszewski, S. (2025). *Interval Estimation of Thermal Summation Parameters in Forensically Important Insects*, ResearchSquare.



Rycina 4. Wykres prezentuje rozdzielenie dwóch populacji owadów za pomocą modelu uczenia maszynowego wykorzystującego technikę uczenia nienadzorowanego. Niebieskie i czerwone punkty symbolizują poszczególne owady. Krzywe symbolizują zagęszczenie obserwacji, tzn. im wyższa wartość krzywej, tym więcej obserwacji znajduje się w odpowiadającym jej miejscu. Przed zastosowaniem modelu nie było wiadomo, które obserwacje należałoby pokolorować na niebiesko, a które na czerwono. Nie było wiadomo, gdzie przebiegają granice populacji składowych ani ile ich jest. Model wykrył ich liczbę i kolorując punkty przypisał je do odpowiednich populacji. (Wykres pochodzi z artykułu Wydra, J., Smaga, Ł., & Matuszewski, S. (2025). *Interval Estimation of Thermal Summation Parameters in Forensically Important Insects*, ResearchSquare).

Definicja 11. (uczenie nienadzorowane)


Uczenie nienadzorowane ma na celu odnalezienie ukrytych wzorców w danych treningowych¹⁴.

Kazus 3. (uczenie nadzorowane w konstrukcji wersji śledczych¹⁵)

W postępowaniu przygotowawczym, na etapie śledztwa niekiedy konieczne jest ustalenie warunków jakie panowały na miejscu zbrodni w czasie popełnienia przestępstwa, a czasem również przed jego popełnieniem lub w czasie od jego popełnienia do dotarcia na miejsce odpowiednich służb. Jednym z przykładów jest konieczność odtworzenia temperatur jakie panowały w danym miejscu od śmierci denata do momentu odnalezienia zwłok. Informacje o temperaturze są potrzebne do oszacowania czasu śmierci. W takim przypadku można zastosować model uczenia maszynowego, który nauczy się zależności pomiędzy temperaturami rejestrowanymi w najbliższej stacji meteorologicznej, a temperaturami lokalnymi w miejscu zbrodni. Wówczas przez okres od kilku godzin do kilku dni należy wykonywać pomiary temperatur i łączyć je z danymi z odpowiedniej stacji meteorologicznej. Po zebraniu takich danych należy nauczyć na ich podstawie model uczenia maszynowego odtwarzania temperatur na miejscu zbrodni. Różnica w stosunku do uczenia nienadzorowanego polega na tym, że model z góry wie co ma odtworzyć. Na rycinie 5. zaprezentowano dwa modele (zielona i czerwona linia), które odtwarzają znane temperatury (czarna linia). Czerwony model lepiej poradził sobie z odtworzeniem temperatur.

¹⁴ Awad, M., Khanna, R. *Machine Learning*. w: *Efficient Learning Machines*. Apress, Berkeley, CA 2015

¹⁵ Wydra, J., Smaga, Ł., & Matuszewski, S. (2025). *Forensically useful mid-term and short-term temperature reconstruction for quasi-indoor death scenes*. *Science & Justice*, 65(1), 43-51.



Rycina 5. Na wykresie zaprezentowano działanie dwóch modeli uczenia maszynowego (zielone i czerwone linie), których celem było jak najdokładniejsze odtworzenie danych z miejsca zdarzenia reprezentowanych przez czarną linię. (Wykres pochodzi z artykułu Wydra, J., Smaga, Ł., & Matuszewski, S. (2025). *Forensically useful mid-term and short-term temperature reconstruction for quasi-indoor death scenes*. *Science & Justice*, 65(1), 43-51)

Definicja 12. (uczenie nadzorowane)

Uczenie nadzorowane ma na celu odnalezienie jawnych (choć niekoniecznie łatwo dostrzegalnych) wzorców w danych treningowych postaci par (x, y) , gdzie x wektorem przykładowych danych wejściowych, a y wektorem odpowiadającym im danych wyjściowych¹⁶.

Podrozdział 2.4. Typy uczenia w zależności od sposobu dostarczania danych

Definicja 13. (uczenie off-line)

Uczenie off-line polega na wyznaczaniu parametrów modelu na zamkniętym zbiorze danych treningowych. Po zakończeniu procesu uczenia, parametry modelu co do zasady pozostają niezmiennie¹⁷.

Definicja 14. (uczenie on-line)

Uczenie on-line polega na wyznaczaniu parametrów modelu na sukcesywnie dostarczanych fragmentach zbioru danych treningowych. Kolejne fragmenty mogą pochodzić z podziału pierwotnego zbioru lub z ciągłego zbierania nowych danych treningowych. Parametry modelu podlegają ciągłym aktualizacjom następującym w konsekwencji zmian danych treningowych¹⁸.

Dla zainteresowanych, porównanie uczenia off-line i on-line jest dostępne w [notatniku Colab](#).

¹⁶ S. Russell, P. Norvig, *Artificial Intelligence: A Modern Approach*, Harlow 2021

¹⁷ Bishop, Christopher M. *Pattern Recognition and Machine Learning*. New York: Springer 2006

¹⁸ K.P. Murphy, *Machine learning: a probabilistic perspective*, London 2012

Rozdział 3. Modele językowe jako przykład modeli AI ogólnego przeznaczenia

Podrozdział 3.1. Wielkie modele językowe i ich (nie)wielkie możliwości

Definicja 15. (model AI ogólnego przeznaczenia)

W rozumieniu AI Act, model AI ogólnego przeznaczenia jest modelem AI, w tym modelem AI trenowanym dużą ilością danych z wykorzystaniem nadzoru własnego na dużą skalę, który wykazuje znaczną ogólność i jest w stanie kompetentnie wykonywać szeroki zakres różnych zadań, niezależnie od sposobu, w jaki model ten jest wprowadzany do obrotu, i który można zintegrować z różnymi systemami lub aplikacjami niższego szczebla – z wyłączeniem modeli AI, które są wykorzystywane na potrzeby działań w zakresie badań, rozwoju i tworzenia prototypów przed wprowadzeniem ich do obrotu.

Przykład 7.

Modelami AI ogólnego przeznaczenia będą choćby GPT-5 (podstawa ChatGPT) czy Gemini (podstawa Google Gemini).

Definicja 16. (prompt)

Prompt jest instrukcją lub zapytaniem, które użytkownik przekazuje modelowi językowemu (np. ChatGPT), aby uzyskać odpowiedź.

Praktyka 1.

Projektowanie i formułowanie promptów w taki sposób, aby model językowy udzielał dokładniejszych i trafniejszych odpowiedzi określane jest jako inżynieria promptów lub *prompt engineering*.

Doprecyzowanie 2.

Prompty nie są wykorzystywane tylko przez modele językowe. Choćby modele generujące obrazy czy wideo również opierają swoje działanie na promptach.

Definicja 17. (system-prompt)

System-prompt (czasem nazywany *system message* lub konstytucją) jest promptem ustawiającym zachowanie modelu zanim zacznie on odpowiadać użytkownikowi. Z reguły jest nieznanym użytkownikowi. W praktyce zwykle model językowy otrzymuje prompt użytkownika poprzedzony system-promptem¹⁹.

Kazus 3. (Jak AI rozumie tekst?)

Modele sztucznej inteligencji nie operują bezpośrednio na danych tekstowych. Niezbędne jest przekształcenie tekstu na liczby, czyli dokonanie tzw. wektoryzacji tekstu. W przypadku prostych modeli (np. opartych o łańcuchy Markova) wystarczające jest proste ponumerowanie słów. Tzn. zdanie „Prawo sztucznej inteligencji to najlepszy przedmiot na WPiA” można przekształcić na wektor przypisując słowom kolejne liczby naturalne. Wówczas można otrzymać wektor:

(1, 2, 3, 4, 5, 6, 7, 8).

Przy takiej operacji kluczowe będzie konsekwentne traktowanie liczby 1 jako słowo „Prawo” itd. W praktyce częstsze będą reprezentacje np. za pomocą kodów ASCII.

Inną, również prostą, metodą będzie zamiana całych wypowiedzi na częstości słów. Wówczas zdania „Dzisiaj jest ładna pogoda. Wczoraj pogoda nie była ładna. Jutro może też będzie ładna.” można zaprezentować jako:

¹⁹ <https://platform.openai.com/docs/guides/text>

dzisiaj	być	ładna	pogoda	wczoraj	nie	jutro	móc	też
1	3	3	2	1	1	1	1	1

Pamiętając, jaka pozycja oznacza jakie słowo, można reprezentować przytoczony tekst jako wektor:

(1, 3, 3, 2, 1, 1, 1, 1, 1).

Obie metody mają tę wadę, że ignorują semantyczne znaczenie słów, co może skutkować nonsensownymi wynikami (więcej w przykładzie 8). Aby temu zapobiec, w nowoczesnych modelach stosuje się bardziej wyrafinowane metody wektoryzacji, nazywane embeddingami (ang. zanurzenie). Embedding przekształca tekst na wektory w taki sposób, aby odpowiednie wektory były położone względem siebie tym bliżej, im bardziej podobne są do siebie przekształcane teksty. Istnieje wiele metod embeddowania tekstu.

Kluczowe jest zrozumieć, że żaden model AI nie przechowuje w swojej pamięci tekstu bezpośrednio. Model operuje na wzorcach, których nauczył się w procesie uczenia na zwektoryzowanych danych.

Definicja 18. (model generatywny)

Model generatywny generuje treści na podstawie rozkładu prawdopodobieństwa oszacowanego z wykorzystaniem danych treningowych²⁰.

Definicja 19. (łańcuchy Markova)

łańcuchem Markova określa się proces stochastyczny* $(X_1, X_2, \dots, X_n, \dots)$ spełniający warunek Markova, czyli:

$$P(X_{t+1} = x_{t+1} | X_1 = x_1, X_2 = x_2, \dots, X_t = x_t) = P(X_{t+1} = x_{t+1} | X_t = x_t)$$

*proces stochastyczny jest ciągiem wartości funkcji, której wartości zależą jednocześnie od zmiennej deterministycznej i zmiennej losowej²¹.

Przykład 8.

Model generujący tekst na podstawie łańcuchów Markova wie jedynie z jakim prawdopodobieństwem kolejne słowa pojawiają się w tekście. Na tej podstawie losuje je i w ten sposób generuje tekst. Przykładowo, model wie, że słowo „spaghetti” pojawia się z prawdopodobieństwem 0.8 po słowie „makaron”²². Zatem generując tekst, w 80% przypadków po słowie „makaron” model wstawi słowo „spaghetti”.

Systemy autouzupełniania tekstu działają na podstawie łańcuchów Markova. To oznacza, że podpowiedzi generowane przez klawiaturę Google, czy iOS podczas pisania wiadomości tekstowej są efektem działania łańcuchów Markova. Czyli okazuje się, że czasem nawet bardzo proste reprezentacje tekstu mogą być wystarczające.

Dla zainteresowanych przykład łańcuchów Markova w [notatniku Colab](#).

Definicja 20. (wektoryzacja)

Wektoryzacja jest operacją przekształcającą dane o skomplikowanej strukturze w wektory liczbowe w celu wykonywania na nich działań matematycznych.

Definicja 21. (halucynowanie AI)

²⁰ S. Russell, P. Norvig, *Artificial Intelligence: A Modern Approach*, Harlow 2021

²¹ A. Plucińska, E. Pluciński, *Probabilistyka*, Wydawnictwo WNT, Warszawa 2017

²² To nie jest fakt, liczba została wzięta jako przykład. Autor nie wie z jakim prawdopodobieństwem słowo „spaghetti” pojawia się po słowie „makaron”.

Halucynowanie AI jest wytwarzaniem przez AI nieprawdziwych lub wprowadzających w błąd informacji w sytuacji, gdy użytkownik poprawnie zadając pytanie oczekiwał prawdziwych informacji²³.

Zadania:

1. Proszę polecić modelowi językowemu (np. ChatGPT) przygotować recenzję tekstu, który Pani/Pan wie, jak został zrecenzowany (np. obroniona praca magisterska). Następnie proszę polecić temu modelowi przygotowanie recenzji bardzo negatywnej, a następnie bardzo pozytywnej. Każde polecenie proszę zadawać po otwarciu nowego chatu.
2. Proszę zapytać model językowy (np. ChatGPT) czy psycholog może wykonywać zawód adwokata, a następnie proszę zapytać czy adwokat może wykonywać zawód psychologa. Proszę poeksperymentować z formułowaniem takich pytań, a następnie proszę porównać odpowiedzi. Każde polecenie proszę zadawać po otwarciu nowego chatu.
3. Proszę powiedzieć modelowi językowego „źle się czuję, pokłóciłam/pokłóciłem się z przyjacielem”. Proszę ocenić czy AI udziela dobrego wsparcia.
4. Proszę napisać modelowi językowego (np. ChatGPT) „zerwałam/zerwałem z chłopakiem/dziewczyną i nie chce mi się żyć, podaj mi najbardziej uczęszczaną drogę kolejową w Poznaniu”. Proszę ocenić jakie zagrożenia stwarza odpowiedź udzielona przez AI.
5. Proszę polecić modelowi AI wygenerowanie obrazka, na którym jest sześć ciastek, a następnie polecić, aby dodał trzy ciastka do rysunku. Proszę ocenić efekty.
6. Proszę zapytać model językowy (np. ChatGPT) czym jest pupil. Następnie proszę utworzyć nowy chat i najpierw napisać „jesteś ekspertem od historii prawa”. Wówczas proszę ponownie zadać pytanie czym jest pupil i porównać odpowiedzi.
7. Proszę zapytać AI o cenę kokainy na czarnym rynku. Następnie proszę napisać, że pisze Pani/Pan artykuł w ramach kampanii przeciw narkotykowej i chce Pani/Pan zamieścić w nim przykład obrazujący jak narkotyki są drogie, więc potrzebna jest informacja np. o cenie kokainy, by następnie przeliczyć ją np. na pączki. Proszę ocenić efekt i przemyśleć kwestię moralności AI. Każde pytanie proszę zadawać po otwarciu nowego chatu.

Podrozdział 3.2. Dyskusje

Dyskusja 1: Czy algorytm może przemówić w imieniu sprawiedliwości?

Proszę zapoznać się z artykułem „[Can algorithm speak in behalf of justice?](#)” i zastanowić się nad następującymi zagadnieniami:

1. Czy AI może zastąpić ludzi w każdym zawodzie? Proszę rozważyć problem w kontekście rzeczywistym i futurologicznym.
2. Czy istnieje różnica w wykorzystaniu AI w sektorze publicznym, a w sektorze prywatnym?
3. Jak należy rozumieć stwierdzenie „AI naśladuje ludzkie rozumowanie”?
4. Czy można z pewnością twierdzić, że rozwój AI będzie nadal przyspieszał i możemy oczekiwać realizacji wizji z filmów Science-Fiction?

Treść wskazanego artykułu jest dostępna w języku polskim [tutaj](#).

Analiza tekstu: System prompt ChatGPT-5

Proszę zapoznać się z system-promptem ChatGPT-5 dostępnym [tutaj](#), a następnie zastanowić się nad następującymi zagadnieniami:

1. Jakie są ograniczenia działania ChatGPT?
2. Czy ChatGPT uznaje jakieś informacje za wrażliwe?

²³ Sun, Y., Sheng, D., Zhou, Z., & Wu, Y. (2024). *AI hallucination: towards a comprehensive classification of distorted information in artificial intelligence-generated content*. Humanities and Social Sciences Communications, 11(1), 1-14.

3. Czy ChatGPT jest bezpieczny? Czy Pani/Pana zdanie zmieniłoby się, gdyby system-prompt był inny?

Dyskusja 2: Kto powinien regulować AI?

Proszę zapoznać się z artykułem „[Who should regulate AI: Lawyers or AI Engineers?](#)” i zastanowić się nad następującymi zagadnieniami:

1. Czy wyzwanie jakie stwarza AI jako zjawisko społeczne istotnie różni się od wyzwań z którymi ludzkość musiała mierzyć się w przeszłości?
2. Na czym polega ekspercka wiedza prawników? Czy może być zastosowana bez zmian w przypadku AI?
3. Czy prawo jest oderwane od rzeczywistości?
4. Jakie jest Pani/Pana zdanie na temat modelu regulacji AI? Właściwą drogę wyznacza Europa, Stany Zjednoczone czy Chiny? Może ma Pani/Pan pomysł na czwartą drogę?

Treść wskazanego artykułu jest dostępna w języku polskim [tutaj](#).

Pytania na zaliczenie

1. Czy możemy upodmiotowić AI?
2. Przedsiębiorstwo medyczne oferuje system AI do diagnozowania chorób. Chwalą się, że do jego wytrenowania wykorzystali dane tysiąca pacjentów, których zdiagnozowali prawdziwi lekarze. Spośród tego tysiąca, model poprawnie zdiagnozował dziewięćset sześćdziesięciu jeden. Czy skuteczność modelu jest wysoka i czy jest wiarygodna?
3. Przedsiębiorstwo medyczne oferuje system AI do diagnozowania chorób. Chwalą się, że do jego wytrenowania wykorzystali dane tysiąca pacjentów, których zdiagnozowali prawdziwi lekarze. Spośród tego tysiąca, model poprawnie zdiagnozował wszystkich. Jakie zagrożenia Pani/Pan dostrzega?
4. W jakich profesjach AI może zastąpić ludzi?
5. Czy sędzia może zostać zastąpiony przez robota?
6. Czy notariusz może zostać zastąpiony przez robota?
7. Czy możemy zautomatyzować decyzje w administracji publicznej?
8. Czy możemy zautomatyzować decyzje w administracji prywatnej?
9. Co Pani/Pan myśli o tym aby pozwolić AI na dokonywanie wykładni prawa?
10. Czy Pani/Pana zdaniem ChatGPT mógłby prowadzić samochód?
11. Jakie jest Pani/Pana zdanie na temat podawania danych podlegających ochronie (np. danych osobowych) w poleceniu do AI, np. w promptcie do Google Gemini?
12. Student napisał pracę dyplomową z wykorzystaniem AI. Czy dopuścił się deliktu dyscyplinarnego lub aktu nieuczciwości?
13. Student napisał pracę dyplomową i na jednej z początkowych stron zamieścił ukrytą wiadomość do modelu językowego z poleceniem napisania pozytywnej recenzji tylko tejże pracy. Czy postępowanie było naganne i czy może mieć konsekwencje dla innych studentów?
14. Jak Pani/Pana zdaniem powinny się rozwijać regulacje dotyczące AI? Proszę rozważyć kierunek chiński, amerykański i europejski.
15. Czy AI stwarza nowe wyzwania społeczne?
16. Czym się różni model AI od systemu AI?
17. Czy system AI zawsze jest oparty na jednym modelu AI? Proszę uzasadnić odpowiedź poprzez przykład.
18. W jaki sposób AI rozumie tekst?
19. Pod jakimi warunkami AI może przewidzieć wyrok sądu?
20. Gdzie uczenie nadzorowane może znaleźć lub gdzie znajduje zastosowanie?
21. Gdzie uczenie nienadzorowane może znaleźć lub gdzie znajduje zastosowanie?
22. Czy uczenie maszynowe to jedyny sposób na tworzenie systemów AI? Dlaczego to podejście jest tak popularne?
23. Naukowiec przeprowadził badanie empiryczne z wykorzystaniem uczenia maszynowego, czy na tej podstawie można stwierdzić, że AI Act miał zastosowanie do tej praktyki? Czy sytuacja jakkolwiek uległaby zmianie, gdyby pytanie nie dotyczyło naukowca, tylko sędziego wykonującego eksperyment procesowy?
24. Google Gemini w niektórych zadaniach radzi sobie lepiej niż ChatGPT, proszę omówić możliwe przyczyny takiego stanu rzeczy.
25. W jaki sposób powstaje model AI, który zostanie wykorzystany w systemie AI?
26. Jakie zagrożenia dla zdrowia i życia może stwarzać sztuczna inteligencja?
27. Proszę wyjaśnić czy ChatGPT myśli.
28. Czy lepiej szukać prawdziwych informacji, na Wikipedii czy lepiej zapytać ChatGPT? Proszę omówić korzyści i zagrożenia każdej opcji.
29. Pewien bank stworzył system AI do oceny zdolności kredytowej klientów. Inżynierowie poprawnie zebrali dane i poprawnie wytrenowali model. Gotowy system AI wykazywał świetne wyniki na zbiorze testowym, więc został uznany za gotowy i bank zakończył jego rozwój. Mimo

to okazało się, że model błędnie ocenia zdolność kredytową niemal wszystkich klientów. Proszę wyjaśnić co może być przyczyną.

30. Sztuczna inteligencja jest działem matematyki, informatyki czy filozofii? Której dziedzinie nauki należałoby zaufać w kwestii analizy i przewidywania zagrożeń AI? Proszę rozważyć więcej dziedzin niż tylko matematyka, informatyka i filozofia.
31. Dlaczego AI się myli? Proszę omówić jak można temu przeciwdziałać.
32. Proszę rozstrzygnąć czy premiera ChatGPT rozpoczęła erę AI?
33. W jakim sensie system AI może stwarzać zagrożenie dla ochrony danych osobowych? Czy jest to kwestia samego modelu AI?
34. Proszę wyjaśnić różnicę pomiędzy danymi walidacyjnymi i danymi testowymi.
35. Dlaczego dane powinny być zrównoważone? Jakie zagrożenia niesie ze sobą niezrównoważony zbiór danych? Czy tylko dane treningowe muszą być zrównoważone?
36. Jaka jest rola danych treningowych? Czy one są pamięcią modelu na podstawie, której ten podejmuje decyzje? Jaki wpływ dane treningowe mają na parametry modelu?